

Universidad Rafael Landívar

Facultad de Ingeniería

Ciencia de Datos

Sección: 3

Ing. Max Cerna

Entrega Proyecto Fase 1

Mauricio Enrique Cabrera Girón – 1073323

Diego de Jesús Urbina Chávez – 1219823

Eduardo David Hernandez Giron – 1156823

Adrián Roberto Morataya Vargas – 1359523

Guatemala, miércoles 23 de septiembre de 2026

Índice de scripts por entregable

El código se entrega en el repositorio. Esta tabla indica en qué archivo está cada uno de los scripts solicitados, para que se puedan revisar sin recorrer el árbol completo.

Entregable	Archivo en el repositorio
1.1 Productor de Kafka (Transmetro y Aerómetro)	ingesta/streaming/productores/productor.py
1.1 Consumidor de Kafka y carga a Bronze	ingesta/streaming/consumidores/consumidor.py
1.1 Carga batch de catálogos	ingesta/batch/cargar_catalogos.py
1.1 Carga batch de MetroRiel	ingesta/batch/cargar_metroriel.py
1.1 Carga batch de Transurbano	ingesta/batch/cargar_transurbano.py
1.1 Carga del log de CDC	ingesta/cdc/cargar_cdc.py
1.1 Contrato común de Bronze e idempotencia	ingesta/comun/bronze.py
1.2 CDC aplicado en orden de secuencia	dbt/models/silver/padron/cdc_padron_evaluado.sql
1.2 Llaves distintas por operador	dbt/models/silver/usuarios/ (tres modelos)
1.3 Silver por fuente	dbt/models/silver/{metroriel, transmetro, aerometro, transurbano}/
1.3 Dimensión zona conformada	dbt/models/silver/_conformadas/dim_zona.sql y map_zona_alias.sql
1.3 Identidad de usuario	dbt/models/silver/_conformadas/dim_persona.sql
1.3 Cuarentena unificada	dbt/models/silver/cuarentena/cuarentena.sql
1.3 Catálogo de reglas y reporte de calidad	dbt/models/reportes/cat_reglas_calidad.sql y rpt_calidad.sql
1.3 SCD Tipo 2 del padrón	dbt/models/silver/padron/slv_padron_scd2.sql
1.3 Seudonimización con sal	dbt/macros/seudonimizar.sql
1.4 DDL de hechos y dimensiones de Gold	docs/gobernanza/ddl_gold.sql
1.4 Diagrama del modelo	docs/gobernanza/modelo_gold.md
1.5 Flujo de orquestación con Prefect	orquestacion/flujo.py
1.5 Verificación de idempotencia	orquestacion/verificar_idempotencia.py
Bitácora de decisiones D-001 a D-012	docs/bitacora.md

1.1 Ingesta por vías y contrato de Bronze

Conteo de filas por archivo

Los nueve archivos entregados por los operadores entraron completos a Bronze. El identificador de lote es la huella SHA-256 del contenido del archivo, de modo que volver a cargar el mismo archivo no produce filas nuevas.

Archivo	Fuente	Filas	Vía de ingesta	Identificador de lote
transmetro_estaciones.csv	tm_estaciones	104	Batch	8552e62903e26caa
transurbano_paradas.csv	tu_paradas	328	Batch	61b069c2505e6a0b
metroriel_estaciones.csv	mr_estaciones	22	Batch	4876704356fe8fe6
aerometro_estaciones.csv	am_estaciones	14	Batch	5fcd8c0d025e41e4
metroriel_viajes.jsonl	metroriel_viajes	299,100	Batch	23feb4a3a55ce506
transurbano_transacciones.csv	transurbano_transacciones	832,791	Batch	89057a42ddbc8e5f
transmetro_validaciones.csv	transmetro_validaciones	363,221	Streaming (Kafka)	7ce830becf569fb7
aerometro_boardings.csv	aerometro_boardings	203,554	Streaming (Kafka)	9e034031c3648122
cdc_padron_usuarios.jsonl	cdc_padron_usuarios	31,050	CDC	c4b938cf1090f0c8
Total		1,730,184		

Por qué Transurbano se carga por batch

Transurbano no expone un flujo en vivo. Entrega un archivo consolidado al cierre de cada día, con la fecha y la hora en columnas separadas y los montos en centavos. No hay ninguna señal de tiempo real que justifique montar un tópico: publicar en Kafka un archivo que ya llegó completo agrega una capa de infraestructura sin ganar nada en latencia. La consecuencia que se asume es explícita: los datos de Transurbano tienen un día de retraso frente a Transmetro y Aerómetro, que sí llegan por streaming. Para las preguntas de planificación de la agencia, que se responden sobre ventanas de semanas o meses, ese retraso no cambia ninguna conclusión. Decisión D-004 de la bitácora.

Por qué Bronze vive en el lake y no en el warehouse

Bronze se guarda como archivos Parquet en lake/bronze/, particionados por fecha de ingesta, y no como tablas del warehouse. Tres razones sostienen la decisión. Primero, Bronze es la copia fiel del dato como llegó: si el operador manda una tarifa en un formato que todavía no sabemos interpretar, el archivo la conserva sin que el warehouse tenga que declarar un tipo para ella. Segundo, el lake permite volver a construir el warehouse completo desde cero sin volver a pedir los archivos a los operadores, y de hecho eso ocurre en cada corrida del pipeline. Tercero, separa el almacenamiento del cómputo: el warehouse puede borrarse y regenerarse en menos de un minuto porque su fuente sigue intacta en el lake. Las capas Silver y Gold sí viven en el warehouse, porque ahí lo que importa es consultar rápido y aplicar restricciones de tipo y de integridad. El caso de MetroRiel ilustra el criterio: su JSON Lines se guarda en Bronze sin aplanar, en una columna payload, y recién en Silver se extraen los campos. Decisión D-003 de la bitácora.

Volumen por capa

La tabla muestra cuántas filas sobreviven en cada capa. La diferencia entre Silver y Gold en Transurbano no es pérdida de datos: son las 41,390 transacciones que el operador rechazó en el momento del cobro (saldo insuficiente o tarjeta inválida). Son transacciones válidas como registro, pero no son abordajes, y por eso quedan en Silver sin promoverse al hecho de abordajes.

Fuente	Modo	Bronze	Silver	Cuarentena	Gold	No promovidas
Aerómetro	AM	203,554	203,554	0	203,554	0
MetroRiel	MR	299,100	299,100	3,589	299,100	0
Transmetro	TM	363,221	363,221	1,115	362,106	1,115
Transurbano	TU	832,791	827,788	5,003	786,398	41,390
Padrón (CDC)	—	31,050	31,050	2,768	—	—

1.2 Captura de cambios y catálogos de usuarios

Alcance del log de CDC

El enunciado menciona el CDC asociado a Transmetro. Al inspeccionar el archivo se encontró que el log no corresponde a un solo operador: las tarjetas que aparecen en él vienen en los tres formatos del sistema, el de Transmetro, el de Transurbano y el de MetroRiel. Se trata entonces del padrón central de la agencia, no de un padrón de Transmetro. Modelarlo como padrón único es lo que permite que una misma persona conserve su perfil y su zona de residencia cuando se mueve entre operadores. Decisión D-005.

Operaciones del log

Operación	Registros en el log	Participación
INSERT (alta de tarjeta)	10,800	34.8 %
UPDATE (cambio de perfil o zona)	16,200	52.2 %
DELETE (baja de tarjeta)	4,050	13.0 %
Total de eventos	31,050	100 %

Las operaciones se aplican en el orden que marca el número de secuencia del log, no en el orden en que las filas aparecen en el archivo ni por la marca de tiempo del commit. La secuencia es la única autoridad de orden, y sobre ella se construye el historial. Decisión D-010.

Conteo de tarjetas antes y después de aplicar los borrados

Momento	Tarjetas	Detalle
Antes de aplicar los DELETE	22,462	Personas distintas con al menos un alta válida en el log
Después de aplicar los DELETE	22,462	El historial conserva a todas: la baja no borra, cambia el estado
De ellas, activas al cierre	19,110	Estado ACTIVA en la versión vigente
De ellas, dadas de baja	3,352	Estado INACTIVA en la versión vigente

Un DELETE no elimina la fila del padrón. Cierra la versión vigente y abre una nueva con estado INACTIVA. Así, una consulta sobre el 20 de junio sigue viendo activa a una tarjeta que se dio de baja en julio, que es justamente lo que un historial debe permitir. De los 4,050 eventos DELETE del log, 3,352 se aplicaron sobre tarjetas válidas y vigentes; el resto fue rechazado por las reglas de calidad que se detallan en la sección 1.3, principalmente bajas repetidas y eventos con la llave centinela.

Historial del padrón en SCD Tipo 2

Métrica	Valor
Versiones generadas	27,428
Personas distintas	22,462
Promedio de versiones por persona	1.22
Máximo de versiones para una misma persona	6

Usuarios únicos por operador

Transurbano, MetroRiel y Aerómetro no entregan padrón de usuarios. Para cada uno se construyó un catálogo mínimo con las llaves distintas que aparecen en su archivo de operación: una sola columna, sin nombre, sin fecha de alta y sin ningún otro atributo, porque el operador nunca entregó esa información. Inventar atributos habría significado documentar como dato algo que no existe en la fuente.

Operador	Usuarios únicos	Naturaleza de la llave
Transurbano	36,567	Número de tarjeta de diez dígitos
MetroRiel	22,885	Tarjeta con prefijo MR y siete dígitos
Aerómetro	14,496	Hash de usuario de doce caracteres hexadecimales
Padrón central (CDC)	22,462	Tarjeta en cualquiera de los tres formatos

1.3 Capa Silver, calidad e identidad

Unificación de formatos

Aspecto	Como llega de la fuente	Como queda en Silver
Fecha y hora de Transurbano	Dos columnas separadas, fecha y hora	Una sola marca de tiempo
Hora de Aerómetro	UTC	Hora local de Guatemala (UTC menos 6)
Montos de Transurbano	Centavos, número entero	Quetzales con dos decimales
Viajes de MetroRiel	JSON Lines anidado	Campos extraídos y tipados
Zona de residencia y de parada	32 variantes de texto libre	16 zonas canónicas vía <code>map_zona_alias</code>
Identificador de abordaje	Distinto en cada operador	Clave única con prefijo del modo

La conversión horaria de Aerómetro se verificó contra el resto de la red: sus abordajes concentran los picos en las horas 7 y 17, las mismas que Transmetro, Transurbano y MetroRiel. Si la conversión no se hubiera aplicado, los picos aparecerían desplazados seis horas, a las 13 y a las 23.




Tabla de cuarentena con motivo de rechazo

Ningún registro se descarta en silencio. Todo lo que no cumple una regla se conserva en silver.cuarentena con su carga original completa, la fuente, el proceso y el motivo del rechazo. Por construcción, para cada fuente se cumple que Bronze es igual a Silver válido más cuarentena, y hay un test automático por fuente que lo verifica en cada corrida.

Fuente	Proceso	Motivo de rechazo	Registros	% de Bronze
Transurbano	transaccion	estacion desconocida	4,186	0.503 %
MetroRiel	trayecto	viaje sin salida	3,589	1.200 %
Padrón (CDC)	padron	llave centinela	2,206	7.105 %
Transmetro	abordaje	duplicado	1,115	0.307 %
Transurbano	transaccion	fecha futura	817	0.098 %
Padrón (CDC)	padron	actualizacion sobre baja	423	1.362 %
Padrón (CDC)	padron	baja repetida	139	0.448 %

Total, en cuarentena			12,475	
-----------------------------	--	--	---------------	--

Lectura de los tres motivos con más peso. estacion_desconocida en Transurbano son transacciones cuyo código de parada viene vacío o no existe en el catálogo; sin parada no se puede ubicar el abordaje en una zona. viaje_sin_salida en MetroRiel son viajes en los que el pasajero no validó al salir: el abordaje es válido y entra a Gold, lo que se rechaza es únicamente el trayecto, porque sin salida no hay origen y destino. llave_centinela en el padrón son eventos cuya tarjeta trae el valor SIN-TARJETA: aceptarlos habría colapsado 2,206 eventos de personas distintas en un único registro inexistente.

Conteo de registros por regla de calidad

El catálogo declara 43 reglas repartidas entre las cinco fuentes. Se declaran todas, incluso las que no rechazaron nada, porque una regla en cero es un resultado: significa que esa fuente no presenta ese problema, no que la regla no se haya evaluado.

Fuente	Reglas declaradas	Reglas con rechazos	Registros en cuarentena
Padrón (CDC)	11	3	2,768
MetroRiel (abordaje)	7	0	0
MetroRiel (trayecto)	5	1	3,589
Transurbano	6	2	5,003
Transmetro	7	1	1,115
Aerómetro	7	0	0
Total	43	7	12,475

Aerómetro no produjo ningún rechazo. Es el operador con menor volumen y su archivo llega con formato homogéneo, un identificador entero correlativo y un hash de usuario de longitud fija. El detalle regla por regla, con su descripción y su porcentaje sobre Bronze, está en el modelo reportes.rpt_calidad del repositorio.

Estrategia de identidad de usuario

Cada operador identifica a sus usuarios con un formato propio: Transmetro usa TC más ocho dígitos, Transurbano diez dígitos, MetroRiel MR más siete dígitos y Aerómetro un hash de doce caracteres. La estrategia adoptada extrae la parte numérica de la tarjeta en los tres primeros y construye con ella una llave de persona única en la red. Aerómetro queda fuera de esa vinculación.

Tipo de identidad	Estado en el padrón	Personas
Vinculada entre operadores	Activa en el padrón	19,110
Vinculada entre operadores	Dada de baja en el padrón	3,352
Vinculada entre operadores	Sin registro en el padrón	33,422
Solo Aerómetro	Sin registro en el padrón	14,496
Total de personas en Gold		70,380

Evidencia que respalda la vinculación

La decisión no se tomó por analogía de formatos. Se verificó contra el padrón: de 5,000 llaves del CDC con formato de Transurbano o de MetroRiel, ninguna aparece con formato de Transmetro, lo que confirma que la parte numérica identifica a la persona y el prefijo identifica al operador emisor. El resultado es consistente con el comportamiento observado: 26,831 personas usan dos modos y 9,996 usan tres, para un total de 36,827 usuarios multimodales sobre 70,380.

Supuestos

Primero, que la parte numérica de la tarjeta es estable en el tiempo para una misma persona y no se reasigna cuando una tarjeta se da de baja. Segundo, que dos tarjetas con la misma parte numérica en operadores distintos pertenecen a la misma persona. Tercero, que el hash de Aerómetro es opaco por diseño del operador y no admite vinculación con el resto de la red.

Límites

La vinculación no es una identificación civil: no hay documento de identidad en ninguna fuente, de modo que dos personas que compartan una tarjeta familiar aparecen como una sola, y una persona con dos tarjetas del mismo operador aparece como dos. Los 14,496 usuarios de Aerómetro no se pueden cruzar con los otros modos, así que cualquier análisis de transferencia hacia o desde el Aerómetro queda fuera de alcance. Y los 33,422 usuarios vinculados que no figuran en el padrón indican que el padrón central cubre solo una parte de quienes efectivamente viajan, por lo que las conclusiones por perfil de usuario solo son válidas para el subconjunto registrado. Decisiones D-002 y D-007.


1.4 Modelo dimensional de Gold

Grano de la tabla de hechos principal

Una fila de `fct_abordaje` representa un abordaje: una persona sube a un vehículo de un modo, en un punto de abordaje, en un instante determinado.

El grano se eligió así porque es el evento más fino que los cuatro operadores registran en común. Transmetro y Transurbano solo capturan la entrada, de modo que un grano de viaje completo con origen y destino habría excluido al 69 por ciento de la demanda. El viaje con origen y destino existe, pero en un hecho aparte, `fct_trayecto_od`, alimentado solo por MetroRiel, que es el único operador que valida también a la salida. Decisión D-001.

Diagrama del modelo



Matriz del bus

Las seis dimensiones son conformadas: significan lo mismo y usan las mismas llaves en los tres hechos, lo que permite cruzarlos en un mismo tablero sin traducciones intermedias.

Proceso de negocio	Fecha	Hora	Modo	Estación	Zona	Persona	Filas
Abordaje	Sí	Sí	Sí	Sí	Sí	Sí	1,651,158
Trayecto origen-destino	Sí	Sí	Sí	Sí (origen y destino)	Sí (origen y destino)	Sí	295,511
Estado diario del padrón	Sí	No	No	No	Sí (residencia)	Sí	559,718

Clasificación de medidas

Medida	Hecho	Tipo	Cómo se puede sumar
cantidad_abordajes	fct_abordaje	Aditiva	Se suma en todas las dimensiones
monto_q	fct_abordaje	Aditiva	Se suma en todas las dimensiones
cantidad_trayectos	fct_trayecto_od	Aditiva	Se suma en todas las dimensiones
distancia_km	fct_trayecto_od	Aditiva	Se suma en todas las dimensiones
tarjetas_activas	fct_estado_padron_diario	Semi aditiva	Se suma entre zonas y perfiles de un mismo día, nunca entre días
cantidad_personas	fct_estado_padron_diario	Semi aditiva	Igual que la anterior: es una foto diaria, no un flujo
personas distintas	Derivada	No aditiva	Se recalcula en cada nivel, nunca se suma
proporción en hora pico	Derivada	No aditiva	Es un cociente, se recalcula
duración promedio	Derivada	No aditiva	Es un promedio, se recalcula

La distinción importa en la práctica. Sumar tarjetas_activas a lo largo de los 45 días daría 859,950, un número sin sentido que contaría a la misma persona una vez por día. El valor correcto para responder cuántas tarjetas hay activas es el del último día: 19,110. En cambio monto_q sí se acumula a lo largo del periodo y da Q 2,755,911.85.

Cifras del modelo

Modo	Abordajes	Recaudación	Personas distintas
Transurbano	786,398	Q 930,162.35	36,567
Transmetro	362,106	Q 296,397.00	43,255
MetroRiel	299,100	Q 816,913.50	22,885
Aerómetro	203,554	Q 712,439.00	14,496
Total de la red	1,651,158	Q 2,755,911.85	70,380

El 41.5 por ciento de los abordajes ocurre en hora pico, definida como las franjas de 06 a 08 y de 16 a 18 en día hábil. Los trayectos de MetroRiel promedian 21.4 minutos. De las dieciséis zonas del área metropolitana, quince tienen servicio: la única sin ningún punto de abordaje es Santa Catarina Pinula, y las más demandadas son Zona 17 con 149,249 abordajes, Zona 12 con 148,573 y Zona 8 con 147,871.

1.5 Orquestación y evidencia de idempotencia

El flujo completo

Un solo comando, `python -m orquestacion.flujo`, corre el pipeline entero con Prefect. Las etapas de ingesta reintentan dos veces ante un fallo transitorio; la construcción con dbt no reintenta, porque es determinista y un fallo ahí indica un error que hay que corregir.

Etapas	Qué hace	Duración
catalogos	Carga los cuatro catálogos de estaciones y paradas	0.06 s
metroriel	Carga los viajes de MetroRiel desde JSON Lines	0.08 s
transurbano	Carga las transacciones de Transurbano	0.08 s
padron_cdc	Carga el log de cambios del padrón	0.02 s
productor_kafka	Publica Transmetro y Aerómetro en sus tópicos	0.06 s
consumidor_kafka	Consume los tópicos y escribe en Bronze	30.95 s
dbt_build	Construye Bronze, Silver, Gold, features y reportes, y corre 226 pruebas	16.88 s
publicar_gold	Publica las nueve tablas de Gold para el tablero	0.84 s
exportar_modelo	Genera el DDL y el diagrama desde el warehouse	0.04 s
Total		49.01 s

Por qué el flujo es idempotente

Cada etapa lo es por construcción. Las cargas a Bronze se identifican por la huella del contenido del archivo y se omiten si el lote ya existe. Silver y Gold se reconstruyen completos desde Bronze en cada corrida. El historial del padrón se deriva del log y no de la hora de ejecución. Y ningún modelo usa la fecha actual como parte de su lógica, de modo que correr el pipeline hoy o mañana produce exactamente el mismo resultado.

Evidencia de las dos corridas

El comando `python -m orquestacion.verificar_idempotencia` corre el flujo completo dos veces seguidas y, después de cada corrida, cuenta las 52 tablas de todas las capas. Además del conteo de filas calcula una huella de contenido por tabla, el XOR del hash de cada fila, que no depende del orden y cambia si cambia una sola fila. Las dos corridas resultaron idénticas en las 52 tablas, en filas y en contenido.

Capa	Tablas	Filas corrida 1	Filas corrida 2	Diferencias
Bronze	9	2,061,624	2,061,624	0
Seeds	2	48	48	0
Silver	28	4,308,236	4,308,236	0
Gold	9	2,607,131	2,607,131	0
Features	1	70,380	70,380	0
Reportes	3	90	90	0
Total	52	9,080,860	9,080,860	0

Resultado: IDEMPOTENTE. Las 226 pruebas de dbt pasaron en ambas corridas, sin advertencias ni errores. El detalle tabla por tabla, con las huellas de contenido, está en [docs/evidencias/idempotencia.md](#) del repositorio, y se regenera cada vez que se corre la verificación.

Pruebas automáticas

Tipo de prueba	Cantidad	Qué garantiza
Unicidad de llaves	21	Ninguna llave primaria se repite
No nulos	Más de 100	Los campos obligatorios están presentes
Integridad referencial	15	Toda llave foránea de Gold resuelve a su dimensión
Conservación por fuente	5	Bronze es igual a Silver válido más cuarentena
Reglas de negocio	Resto	Una sola versión vigente por persona, vigencias ordenadas, entre otras
Total	226	

Anexo Bitácora de decisiones

Cada decisión de diseño quedó registrada con su alternativa descartada y su consecuencia asumida. El texto completo está en docs/bitacora.md.

ID	Decisión	Consecuencia asumida
D-001	Grano de abordaje para el hecho principal y hecho aparte para trayectos origen-destino	El análisis origen-destino cubre solo MetroRiel
D-002	Identidad de persona por la parte numérica de la tarjeta	Aerómetro no se vincula con el resto de la red
D-003	Bronze en el lake como Parquet; Silver y Gold en el warehouse	Bronze no se consulta con SQL directo sino a través de vistas
D-004	Transurbano se ingesta por batch	Un día de latencia frente a las fuentes de streaming
D-005	El CDC es el padrón central de la agencia, no de un operador	Las tarjetas SIN-TARJETA van a cuarentena
D-006	Los estados 7 y 9 de Transurbano son rechazos del operador, no errores de calidad	41,390 transacciones quedan en Silver sin promoverse a Gold
D-007	Seudonimización con sal secreta fuera del repositorio	Sin la sal, la construcción de Gold falla de forma deliberada
D-008	Hora pico de 06 a 08 y de 16 a 18 en día hábil	Los fines de semana no tienen hora pico aunque haya demanda
D-009	Patrón de cuarentena con motivo y test de conservación por fuente	Un viaje sin salida es abordaje válido y trayecto inválido
D-010	El CDC se aplica en orden de secuencia; el SCD Tipo 2 se deriva del log	Un DELETE no borra: abre una versión inactiva
D-011	Foto diaria del padrón con medida semi aditiva	tarjetas_activas no se puede sumar entre días
D-012	Orquestación con Prefect y verificación de idempotencia por conteo y contenido	Las etapas de fuentes no integradas se omiten sin detener el flujo

Para reproducir todo el contenido de este documento: clonar el repositorio, configurar la sal de pseudonimización en el archivo .env, levantar Kafka con docker compose up -d y ejecutar python -m orquestacion.verificar_idempotencia. El pipeline completo corre en menos de un minuto.