Informe de la Fase 2 — Churn de la Red Metropolitana de Transporte

Universidad Rafael Landívar · Ciencia de Datos · Segundo Semestre 2026 Proyecto 2 · Agencia Metropolitana de Transporte
Repositorio: https://github.com/MauricioECabrera/red-metropolitana · etiqueta fase-2 Equipo: Miguel Cabrera (integración y producción), Diego Urbina (etiqueta, población y features), Adrián (modelos), Eduardo Hernández (umbral, test B y segmentación)

1. El problema

Con lo que la Agencia sabe de un usuario hasta la fecha de corte, ¿qué tan probable es que deje de usar la red en los próximos 30 días? Y con esa probabilidad, ¿a quién conviene contactar con la campaña de retención, que no alcanza para todos?

Es un problema de clasificación binaria por unidad y fecha de corte: todo lo que el modelo ve es anterior al corte, y la etiqueta se calcula solo con datos desde el corte en adelante. Los datos son simulados, igual que en el Proyecto 1, con el mismo periodo de 90 días (1 de junio al 29 de agosto de 2026) usado en los tres cortes del proyecto.

- **Unidad:** la Persona (persona_key), para modelar el abandono real de la red integrada y no confundir con abandono a quien solo cambia de tarjeta. Definición completa y costo de esta elección en docs/etiqueta_y_features.md.
- **Etiqueta:** positivo (1) si la persona no tiene ningún abordaje válido en los 30 días que empiezan en la fecha de corte; negativo (0) en otro caso.
- **Población por corte:**

Corte	Fecha	Población	Positivos	Tasa positiva
A (entrenamiento)	2026-07-01	59,515	7,098	0.1193
B (test único)	2026-07-31	58,128	6,383	0.1098
C (producción)	2026-08-30	57,711	—	Etiqueta oculta

2. Sección 2.1 — Ensemble y sesgo-varianza

Se entrenó un ensemble HistGradientBoostingClassifier con las mismas diez variables y los mismos cinco folds de validación cruzada estratificada usados por las líneas base y la logística de la Fase 1, para que la comparación sea justa.

Modelo	AP validación	DE	AP entrenamiento	Brecha	Entrenamiento 5 folds (s)
Baseline tasa constante	0.1193	0.00005	0.1193	0.0000	—
Baseline ranking	0.3898	0.0036	0.3893	−0.0004	—
Logística L1 (λ=100)	0.4079	0.0041	0.4078	−0.0001	0.61
Logística L2	0.4066	0.0042	0.4071	0.0006	—
Ensemble (elegido)	**0.4289**	**0.0024**	**0.4697**	**0.0408**	**2.15**

El ensemble supera a la mejor logística (L1, λ=100) en los cinco folds, con diferencias de 0.0149 a 0.0260 de AP, y a la línea base de ranking en 0.0392.

Sesgo y varianza por modelo:

- *Baseline tasa:* sin brecha, pero sin capacidad: usa solo la tasa global.
- *Baseline ranking:* brecha −0.0004, equilibrado pero limitado por depender de una sola variable con regla fija.
- *Logística L1:* brecha −0.0001, equilibrada; su techo es la estructura lineal regularizada.
- *Logística L2:* brecha 0.0006, también equilibrada, con menor AP que L1.
- *Ensemble:* brecha 0.0408 (AP entrenamiento 0.4697 vs. validación 0.4289), el de mayor varianza del grupo — es decir, el que más se ajusta a su propio entrenamiento — pero aun así el de mejor AP de validación, por lo que se acepta el sobreajuste relativo a cambio de la mejora.

Diez importancias por permutación (calculadas sobre la validación de cada fold, no sobre entrenamiento; caída media de Average Precision):

Variable	Caída media de AP
dias_desde_ultimo_viaje	0.2577
tendencia_viajes_14d	0.0221
gasto_28d_q	0.0089
dias_activos_28d	0.0076
viajes_28d	0.0059
viajes_7d	0.0041
gasto_promedio_viaje_q	0.0037
abordajes_fin_semana_28d	0.0022
proporcion_hora_pico_28d	0.0019
operadores_distintos_28d	0.0002

La recencia (días desde el último viaje) domina por mucho al resto; la tendencia de viajes entre quincenas aparece en segundo lugar.

Decisión: se lleva el ensemble a producción. La mejora de +0.021 de AP sobre la mejor logística, consistente en los cinco folds, justifica su mayor complejidad y menor interpretabilidad; se compensa la falta de coeficientes con signo con las importancias por permutación. Detalle completo en docs/decision_modelo.md y docs/metricas_fase2_ensemble.md.

3. Sección 2.2 — Umbral según costo y test único

Escenario de costos (fijo para todos los grupos): contactar cuesta Q5; si el usuario se iba a ir, la campaña lo retiene el 25 % de las veces; un usuario retenido vale Q60.

Ganancia esperada por contacto: $E[G] = 15p - 5$. Conviene contactar cuando $p > 1/3 \approx 0.3333$ (el umbral teórico del punto de equilibrio).

El umbral de producción no es ese 1/3 teórico, sino **0.31**: el que maximiza la ganancia **observada** (no la esperada) sobre las predicciones fuera de fold del corte A, con las etiquetas reales. Se prefiere así porque no depende de que el modelo esté bien calibrado. La diferencia con el máximo de ganancia esperada (umbral 0.33, Q11,728.60) es de solo Q220 sobre Q11,510 observados en 0.31 — las dos curvas casi se superponen, señal de que el modelo está razonablemente calibrado en A. Con la versión de cinco variables de la Fase 1 el umbral había sido 0.33; al recalcularlo con el ensemble de diez variables bajó a 0.31, con Q220 más de ganancia y 964 contactos más. Derivación completa y curva de ganancia en docs/metricas_umbral.md.

Evaluación única en el corte B (commit 2ba297c903766f792e1aea29d872f2a8c2974d24, 2026-11-08 12:25:50 — registrada una sola vez; el script se niega a correr de nuevo si el registro ya existe):

Dato	Validación cruzada en A	Test en B
Average Precision	0.4276	0.3712
Contactados con umbral 0.31	6,653	6,602
Precisión en el umbral	0.4487	0.4055
Recall en el umbral	0.4205	0.4194
Ganancia observada	Q11,510	Q7,145

La política sigue siendo rentable en B (Q7,145 contra −Q194,895 de contactar a todos y Q0 de no contactar a nadie), pero la ganancia cae. El recall casi no cambia; lo que baja es la precisión. Se revisaron tres hipótesis: distribución distinta entre cortes (explica una parte: la tasa positiva bajó de 0.1193 a 0.1098), varianza de muestra (insuficiente: la caída observada está unas 23 desviaciones estándar por debajo de los folds de A) y desfase temporal de calibración (causa principal: entre los contactados de mayor riesgo, $p > 0.5$, el modelo predijo en promedio 0.6100 en B pero solo abandonó el 0.5034, mientras que en A ambas cifras estaban cerca). El umbral se aplicó tal como estaba congelado y no se ajustó después de ver B. Diagnóstico completo en docs/test_b.md.

4. Sección 2.3 — Segmentación con KMeans y PCA

Se aplicó KMeans sobre las diez features del corte A, escaladas con StandardScaler; la etiqueta no participa en el ajuste, solo se usa después para describir la tasa de abandono por segmento.

Elección de k = 6 (con las cinco variables de la versión anterior había sido 5): el codo de la inercia es el criterio principal (caídas de 28 a 60 mil hasta k=6, luego 19 mil o menos); la silueta queda casi plana con diez variables (0.1958 a 0.2214) y no distingue un k claro, pero k=6 (0.2151) es su máximo local. Se descarta k=2 pese a tener la silueta más alta (0.3838) porque solo separa a los muy activos del resto y esconde al grupo que más abandona dentro del 84 % restante de la población.

PCA a dos componentes: 42.10 % + 13.08 % = 55.18 % de varianza explicada. El componente 1 es intensidad de uso; el componente 2 es tendencia reciente (sube con más viajes en las últimas dos semanas que en las dos anteriores).

Seg.	Nombre	Tamaño	%	Tasa de abandono
0	Viajeros regulares	15,832	26.6	0.0916
1	Viajeros frecuentes multimodales	8,286	13.9	0.0181
2	Viajeros ocasionales de tarifa alta	10,532	17.7	0.1106
3	Viajeros intensivos multimodales	1,128	1.9	0.0177
4	Viajeros en enfriamiento	8,062	13.5	0.4092
5	Viajeros regulares multimodales	15,675	26.3	0.0647

El segmento 4 (en enfriamiento: mediana de 17 días sin viajar, tendencia −3) concentra el 46.5 % de los positivos del corte A con solo el 13.5 % de la población. La tasa de abandono por segmento es descriptiva, no causal: el segmento se construyó con las mismas conductas que ya anticipan el abandono.

Acciones de retención (al menos dos exigidas, se definieron cinco): contacto directo con recarga de cortesía de corta vigencia para el segmento 4; paquete de descuento en Aerómetro para el segmento 2 (paga Q3.50 por viaje, el segundo con más abandono); mensajes de servicio sin incentivo monetario para el segmento 0; promoción de transbordo para el segmento 5; y sin campaña de retención (solo programa de lealtad) para los segmentos 1 y 3, de abandono mínimo. Reporte completo en docs/segmentos.md.

5. Sección 2.4 — MLOps: predicción, modelo guardado y ficha

predecir.py recibe la carpeta de datos y la fecha de corte (python predecir.py --datos <carpeta> --fecha-corte 2026-08-30), compara sus conteos contra Bronze antes de predecir, carga modelos/modelo_churn_v1.joblib sin reentrenar, y produce un CSV con unidad_id, tarjetas (llaves originales separadas por ;), puntaje y contactar.

Predicciones oficiales del corte C (2026-08-30): 57,711 filas, 7,408 contactados (12.8 %), umbral 0.31. Archivo predicciones/predicciones_2026-08-30.csv, SHA-256 ef3c2a3cea1f7c47827a7e049b94a522db06fe09ee279ba0684124926660c74c.

Entorno reproducible: todas las dependencias en requirements.txt con versión fija (==), semilla 42 en folds, modelos y KMeans, y un README.md con los pasos para correr el proyecto completo en otra máquina.

Ficha del modelo (docs/ficha_modelo.md): modelo, versión y commit de entrenamiento; datos y período; unidad; población por corte; etiqueta; comparación de modelos; métricas en validación y en B; lógica de negocio del umbral; predicciones de producción; validaciones de integridad; limitaciones; y el aviso de que los datos son simulados.

6. Validaciones de integridad

Validación	Resultado	Bitácora
Fuga de datos en las features del modelo (prueba de recorte, corte B)	Sin fuga: puntaje y contactar idénticos en las 58,128 filas	D-016
Fuga de datos futura en features.unidad_tarjetas	Encontrada (2,642 de 58,128 filas) y corregida acotando a fecha_corte	D-016, D-017
Idempotencia del flujo completo (dos corridas desde entorno vacío)	Idéntico: 19,712,750 filas iguales en las 25 tablas de todas las capas	D-021
Umbral y modelo congelados antes de evaluar B	Sin fuga de selección: B se evaluó una sola vez, sin reajustar nada después	D-019, D-020

7. Limitaciones

- El modelo pierde calibración de un mes a otro (ver diagnóstico de B en la sección 3): hay que vigilar en producción la precisión real de los contactados y reentrenar cuando haya etiqueta del corte más reciente.
- El ensemble no da coeficientes con signo ni explicaciones causales; su interpretación se apoya en importancias por permutación, no en una relación causal declarada.
- La evaluación de B es única e irrepetible por diseño: no hay forma de "reintentar" el umbral con B sin invalidar la prueba.
- La segmentación es descriptiva: la tasa de abandono por segmento no prueba que pertenecer al segmento cause el abandono.
- Los datos son simulados, igual que en el Proyecto 1; las cifras de negocio (ganancia, costos) son ilustrativas del método, no observaciones reales de la Agencia.

Fuentes

docs/etiqueta_y_features.md, docs/metricas_fase2_ensemble.md, docs/decision_modelo.md, docs/metricas_umbral.md, docs/test_b.md, docs/segmentos.md, docs/ficha_modelo.md, docs/umbral/umbral_elegido.json, docs/umbral/registro_test_b.json, modelos/modelo_churn_v1.json, docs/bitacora.md (D-013 a D-021), docs/evidencias/idempotencia.md. Índice completo de scripts por entregable en docs/entrega_fase2/indice_scripts.md.